机2单变量线性回归

根据城市人口数量，预测开小吃店的利润 数据在ex1data1.txt里，第一列是城市人口数量，第二列是该城市小吃店利润。

In [1]:
```
import numpy as np #Numpy是使用C语言实现的一个数据计算库，它用来处理相同类型，固定长度的元素。
#使用numpy操作数据时，系统运行的速度比使用python代码快很多。numpy中还提供了很多的数据处理函数，例如傅里叶变化，矩阵操作，数据拟合等操作
import pandas as pd #Pandas 是基于NumPy 的一种工具，该工具是为了解决数据分析任务而创建的。
#Pandas纳入了大量库和一些标准的数据模型，提供了大量能使我们快速便捷地处理数据的函数和方法
import matplotlib.pyplot as plt #2D绘图库。提供一个类似matlab的绘图框架
```

In [2]:
```
data = pd.read_csv('2.txt', header=None, names=['Population', 'Profit']) #header:指定标题行
data.head() #head函数可以默认读取前5行的数据
```

Out[2]:

	Population	Profit
0	6.1101	17.5920
1	5.5277	9.1302
2	8.5186	13.6620
3	7.0032	11.8540
4	5.8598	6.8233

In [3]:
```
data.plot(kind='scatter',title='city and profit',x='Population',y='Profit',figsize=(10,10)) #scatter:散点图 figsize: 宽高
plt.show()
```

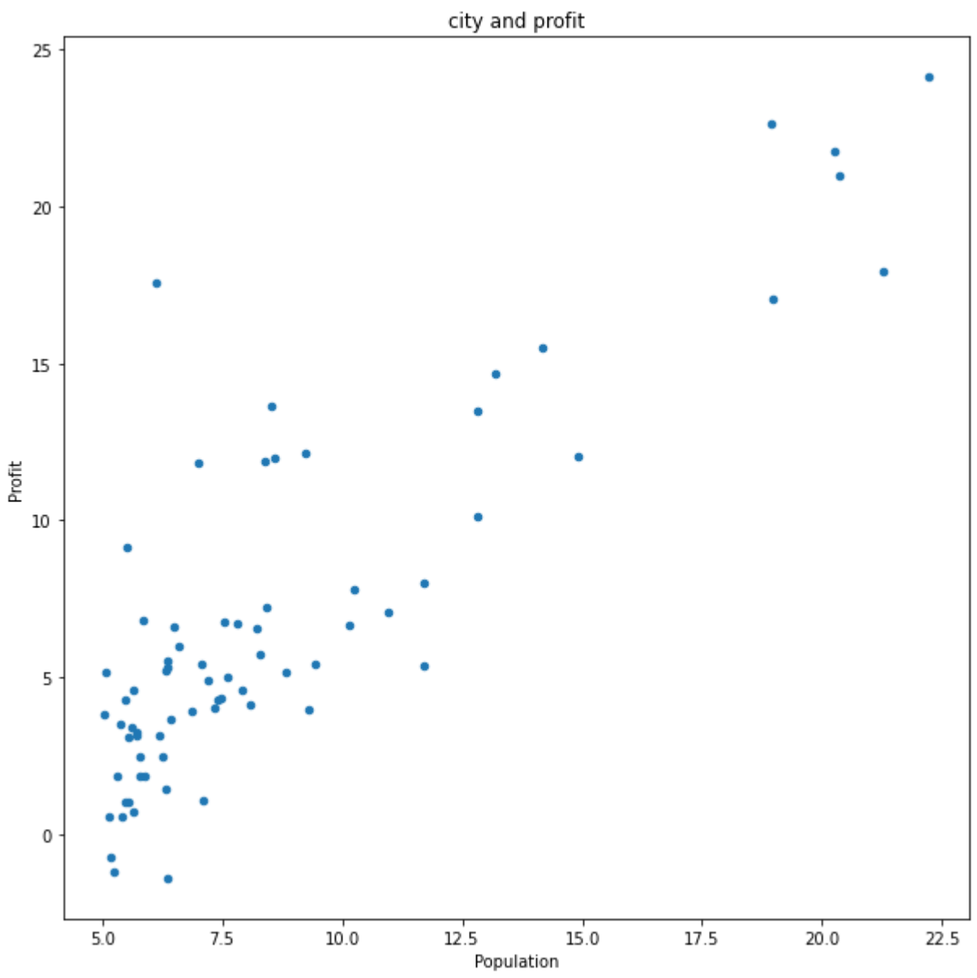

梯度下降

这个部分需要在现有数据集上，训练线性回归的参数θ

In [4]:
```
#定义costFunction
def computeCost(X,y,theta):
    inner=np.power((X*theta.T)-y,2) #power(x, y):计算 x 的 y 次方,theta.T:theta的转置
    return np.sum(inner)/(2*len(X))  #len:字符串长度
```

In [5]:
```
data.insert(0,'Ones',1) #在data的第0列插入1，名为Ones，用于更新θ0
```

In [6]:
```
#变量初始化
cols=data.shape[1] #读取data列数 若shape[0]则是行数
X=data.iloc[:,:-1] #X是data里的除最后列，前面的冒号就是取行数，后面的冒号是取列数
y=data.iloc[:,2:] #y是data最后一列
```

In [7]:
```
X.head()
```

Out[7]:

	Ones	Population
0	1	6.1101
1	1	5.5277
2	1	8.5186
3	1	7.0032
4	1	5.8598

In [8]:
```
y.head()
```

Out[8]:

	Profit
0	17.5920
1	9.1302
2	13.6620
3	11.8540
4	6.8233

In [9]:
```
X=np.matrix(X.values) #用于从类数组对象或数据字符串返回矩阵
y=np.matrix(y.values)
theta=np.matrix(np.array([0,0]))
```

In [10]:
```
X.shape,y.shape,theta.shape,theta
```

Out[10]:
```
((72, 2), (72, 1), (1, 2), matrix([[0, 0]]))
```

In [11]:
```
computeCost(X,y,theta)
```

Out[11]: 40.175290826974305

梯度下降

一个检查梯度下降是不是在正常运作的方式，是打印出每一步J()的值，看他是不是一直都在减小，并且最后收敛至一个稳定的值。 最后的结果会用来预测小吃店在35000及70000人城市规模的利润

In [12]:
```
# θ 更新
def gradientDescent(X,y,theta,alpha,iters): #X:人口， y: 利润， theta：[θ0， θ1]初始化为[0,0]， alpha:学习率， iters：迭代次数
    temp=np.matrix(np.zeros(theta.shape)) #返回来一个theta形状和类型的用0填充的数组
    parameters=int(theta.ravel().shape[1]) #将数组维度拉成一维数组，取列数（2）， θ的数量
    cost=np.zeros(iters) #初始化

    for i in range(iters): #迭代1500次
        error=(X*theta.T)-y  #每次迭代都检查J（θ）的值

        for j in range(parameters):
            term=np.multiply(error,X[:,j]) #j=0时相当于都*1
            temp[0,j]=theta[0,j]-((alpha/len(X))*np.sum(term)) #len:字符串长度即m，更新θ

        theta=temp #确定本次迭代的θ
        cost[i]=computeCost(X,y,theta)

    return theta,cost
```

In [13]:
```
alpha=0.01
iters=1500
```

In [14]:
```
g,cost=gradientDescent(X,y,theta,alpha,iters)
g
```

Out[14]: matrix([[-3.01902296, 1.14867812]])

In [15]:
```
predict1=[1,3.5]*g.T
print("predict1:",predict1)
predict2=[1,7]*g.T
print("predict2:",predict2)
```

```
predict1: [[1.00135045]]
predict2: [[5.02172387]]
```

In [16]:
```
x=np.linspace(data.Population.min(),data.Population.max(),100) #创建等差数列
f=g[0,0]+(g[0,1]*x)
fig,ax=plt.subplots(figsize=(12,8)) #fig:绘图窗口(Figure),ax:绘图窗口上的坐标系(axis),figsize:子图的宽度和高度
ax.plot(x,f,'r',label='Prediction') #'r':红线， label：定义图例
ax.scatter(data.Population,data.Profit,label='Training Data') #散点图
ax.legend(loc=2) #在图上标明一个图例，用于说明每条曲线的文字显示， loc参数，用于控制图例的所在象限
ax.set_xlabel('Population')
ax.set_ylabel('Profits')
ax.set_title('Predicted Profit vs. Populations Size')
plt.show
```

Out[16]: <function matplotlib.pyplot.show(close=None, block=None)>

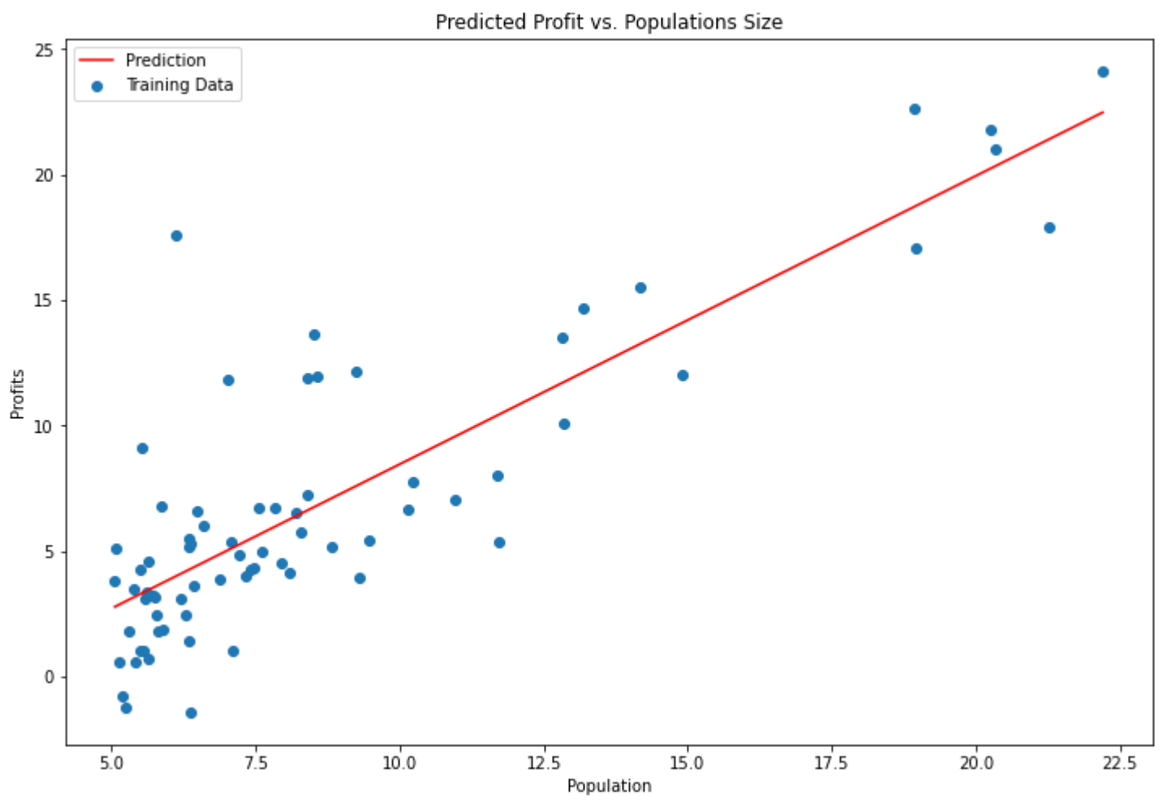

机4多变量线性回归

In [17]:
```
data2=pd.read_csv('4.txt',header=None,names=['Size','Bedrooms','Price'])
data2.head()
```

Out[17]:

	Size	Bedrooms	Price
0	2104	3	399900
1	1600	3	329900
2	2400	3	369000
3	1416	2	232000
4	3000	4	539900

特征归一化

In [18]:
```
#观察数据发现，size变量是bedrooms变量的1000倍大小,统一量级会让梯度下降收敛的更快。做法就是，将每类特征减去他的平均值后除以标准差
data2=(data2-data2.mean())/data2.std() #std:计算标准差
data2.head()
```

Out[18]:

	Size	Bedrooms	Price
0	0.130010	-0.223675	0.475747
1	-0.504190	-0.223675	-0.084074
2	0.502476	-0.223675	0.228626
3	-0.735723	-1.537767	-0.867025
4	1.257476	1.090417	1.595389

In [19]:
```
# 加一列常数项
```

```
data2.insert(0, 'Ones', 1)

# 初始化X和y
cols = data2.shape[1]
X2 = data2.iloc[:,0:cols-1]
y2 = data2.iloc[:,cols-1:cols]

# 转换成matrix格式，初始化theta
X2 = np.matrix(X2.values)
y2 = np.matrix(y2.values)
theta2 = np.matrix(np.array([0,0,0]))

# 运行梯度下降算法
g2, cost2 = gradientDescent(X2, y2, theta2, alpha, iters)
g2
```

Out[19]:
```
matrix([[-1.10856950e-16,  8.84042349e-01, -5.24551809e-02]])
```

正规方程

In [20]:
```
def normalEqn(X, y):
    theta = np.linalg.inv(X.T@X)@X.T@y #X.T@X等价于X.T.dot(X)，np.linalg.inv()：矩阵求逆
    return theta
```

In [21]:
```
final_theta2=normalEqn(X, y)#这里用的是data1的数据
final_theta2
```

Out[21]:
```
matrix([[-3.20203277],
        [ 1.16586523]])
```